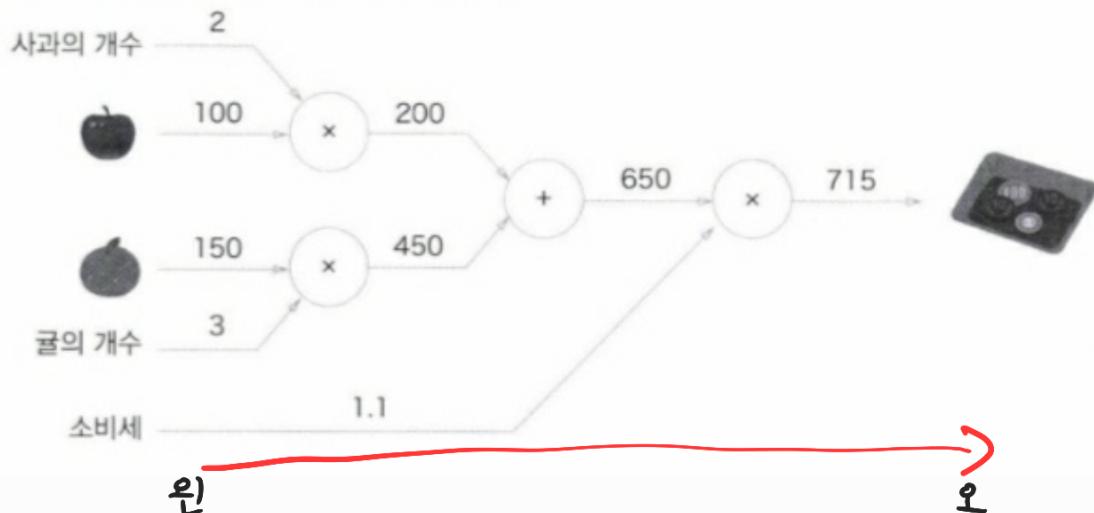


계산 그래프를 이용한 역전파

계산 그래프 : 계산과정을 그래프로 나타낸 것.(node와 edge로 구성)



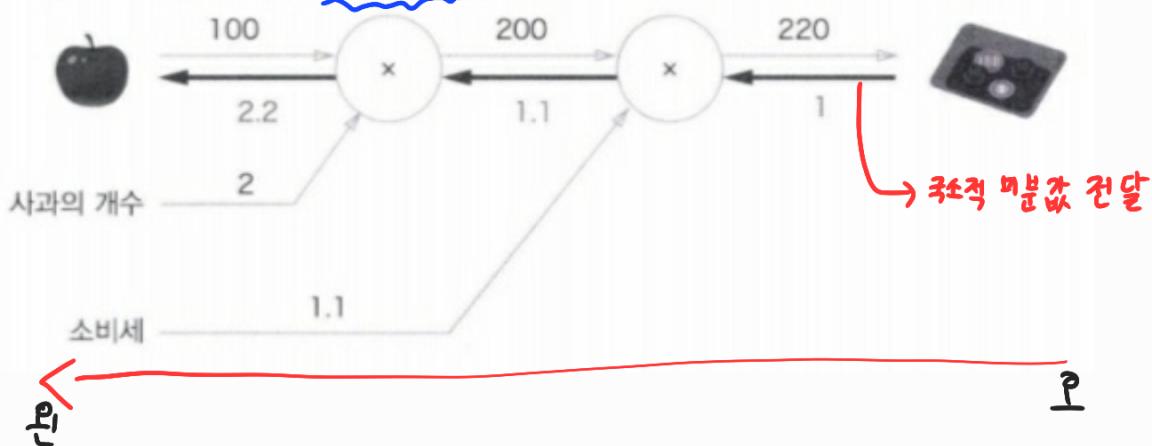
왼쪽에서 오른쪽으로 가는 것을 순전파라고 함

오른쪽에서 왼쪽으로 가는 것을 역전파라고 함

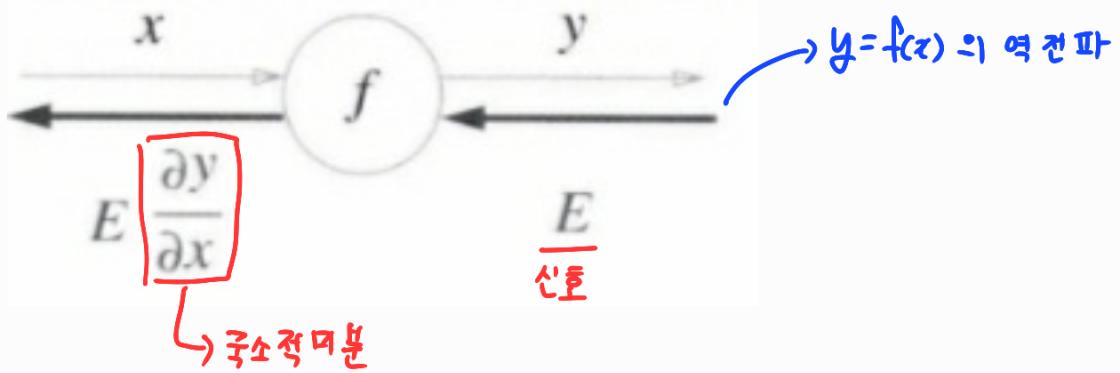
계산 그래프의 특징 :

- 국소적 계산(자신과 직접 관계된 작은 범위)을 전파하여 최종 결과를 도출하게 된다.
- 중간 계산 결과를 모두 보관할 수 있다.
- 역전파를 통해 '미분'을 효율적으로 계산할 수 있다.

그림 5-5 역전파에 의한 미분 값의 전달



연쇄법칙

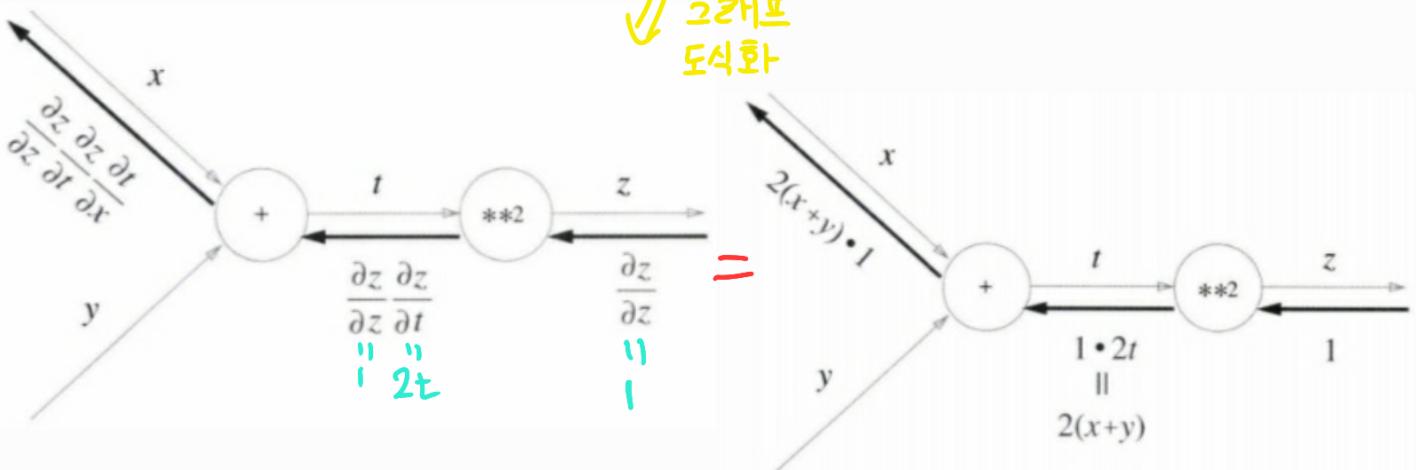


- 합성 함수 : 여러 함수로 구성된 함수

: 합성 함수의 미분은 합성 함수를 구성하는 각 함수의 미분의 곱으로 나타낼 수 있다. \Rightarrow 연쇄 법칙의 원리

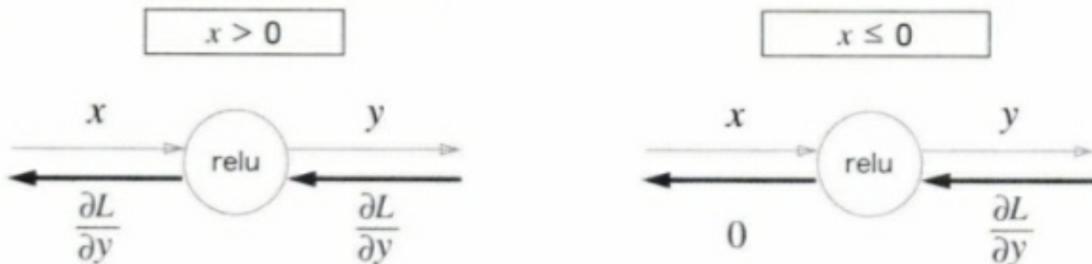
$$\underbrace{\frac{\partial z}{\partial x} = \frac{\partial z}{\partial t} \frac{\partial t}{\partial x}}_{\text{원칙}} \quad \left[\begin{array}{l} \frac{\partial z}{\partial t} = 2t \\ \frac{\partial t}{\partial x} = 1 \end{array} \right] \quad \frac{\partial z}{\partial x} = \frac{\partial z}{\partial t} \frac{\partial t}{\partial x} = 2t \cdot 1 = 2(x+y)$$

그리프
도식화



- ReLU 계층 구현

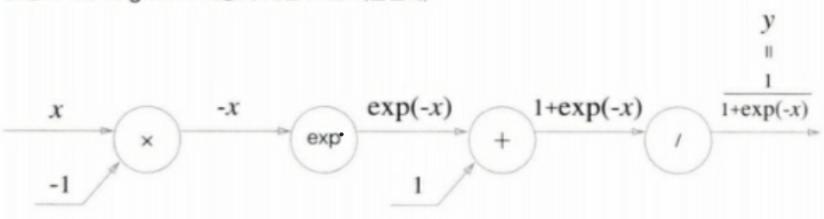
$$\text{ReLU} = y = \begin{cases} x & (x > 0) \\ 0 & (x \leq 0) \end{cases} \quad \frac{\partial y}{\partial z} = \begin{cases} 1 & (z > 0) \\ 0 & (z \leq 0) \end{cases}$$



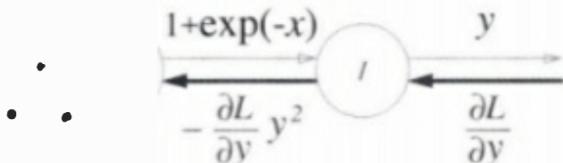
- Sigmoid 계층 구현

그림 5-19 Sigmoid 계층의 계산 그래프(순전파)

$$\text{Sigmoid} = y = \frac{1}{1 + \exp(-x)}$$

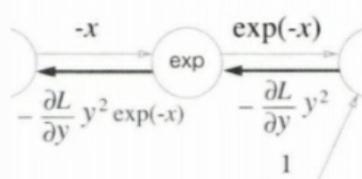


$$1. \text{ 나눗셈 연산 } \text{ ex) } y = \frac{1}{x} \Rightarrow \frac{dy}{dx} = -\frac{1}{x^2} = -y^2$$



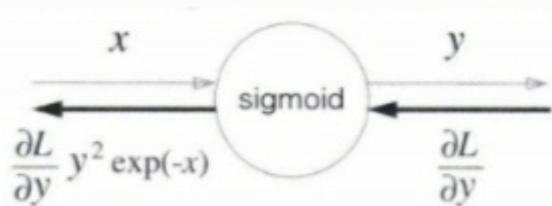
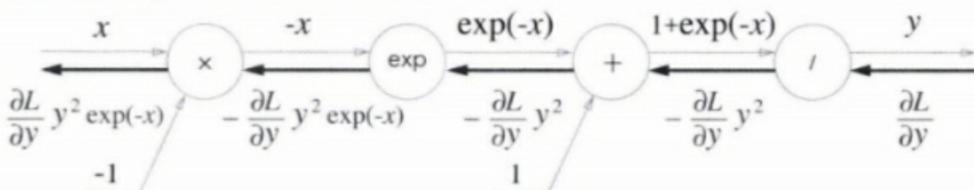
2. 덧셈연산 \Rightarrow 여과없이 하류로 내보냄

$$3. \text{ Exp 연산 } \Rightarrow \exp(x) \Rightarrow \frac{d\exp}{dx} = \exp(x)$$



4. 곱셈 연산 \Rightarrow 순전파 때의 값을 서로 바꿔 곱함

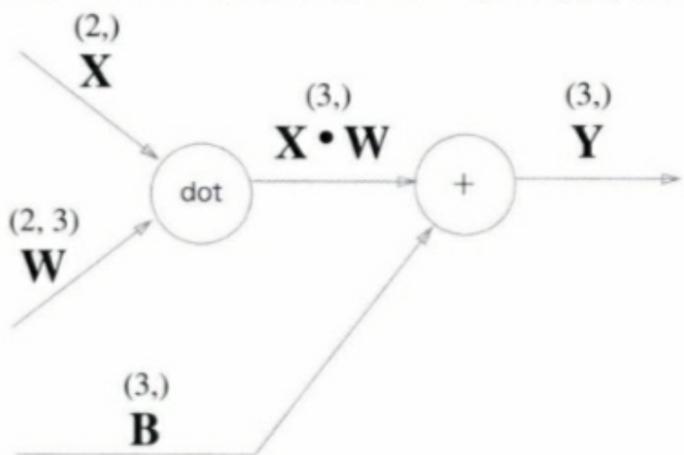
그림 5-20 Sigmoid 계층의 계산 그래프



$$\begin{aligned} \frac{\partial L}{\partial y} y^2 \exp(-x) &= \frac{\partial L}{\partial y} \frac{1}{(1 + \exp(-x))^2} \exp(-x) \\ &= \frac{\partial L}{\partial y} \frac{1}{1 + \exp(-x)} \frac{\exp(-x)}{1 + \exp(-x)} \\ &= \frac{\partial L}{\partial y} y(1-y) \end{aligned}$$

- Affine 계층 구현

: Affine 변환이란 신경망의 순전파 때 수행하는 행렬의 곱을 의미

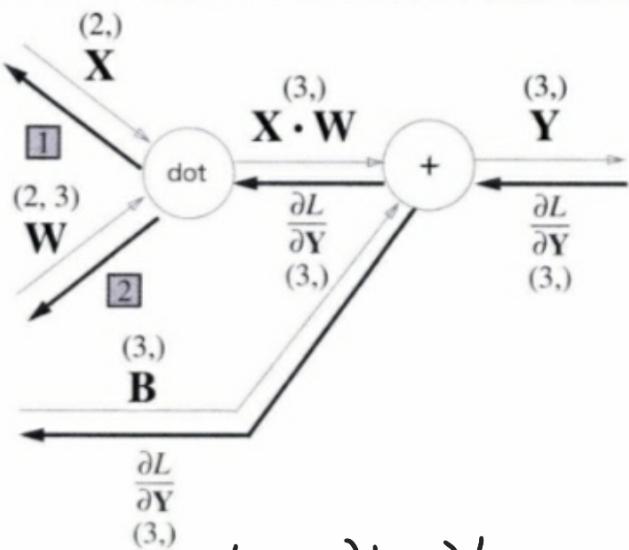


$$\frac{\partial L}{\partial X} = \frac{\partial L}{\partial Y} \cdot W^T$$

$$\frac{\partial L}{\partial X} = X^T \cdot \frac{\partial L}{\partial Y}$$

① $\frac{\partial L}{\partial X} = \frac{\partial L}{\partial Y} \cdot W^T$
 $(2,) \quad (3,) \quad (3, 2)$

② $\frac{\partial L}{\partial W} = X^T \cdot \frac{\partial L}{\partial Y}$
 $(2, 3) \quad (2, 1) \quad (1, 3)$



⇒ Shape에 주의 !!

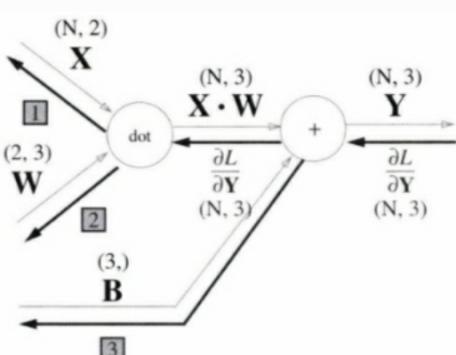
$$X = (\pi_0, \pi_1, \dots, \pi_n) \quad \frac{\partial L}{\partial X} = \left(\frac{\partial L}{\partial \pi_0}, \frac{\partial L}{\partial \pi_1}, \dots, \frac{\partial L}{\partial \pi_n} \right)$$

$$X.\text{shape} == \frac{\partial L}{\partial X}.\text{shape}, \quad W.\text{shape} == \frac{\partial L}{\partial W}.\text{shape}$$

① $\frac{\partial L}{\partial X} = \frac{\partial L}{\partial Y} \cdot W^T$
 $(N, 2) \quad (N, 3) \quad (3, 2)$

② $\frac{\partial L}{\partial W} = X^T \cdot \frac{\partial L}{\partial Y}$
 $(2, 3) \quad (2, N) \quad (N, 3)$

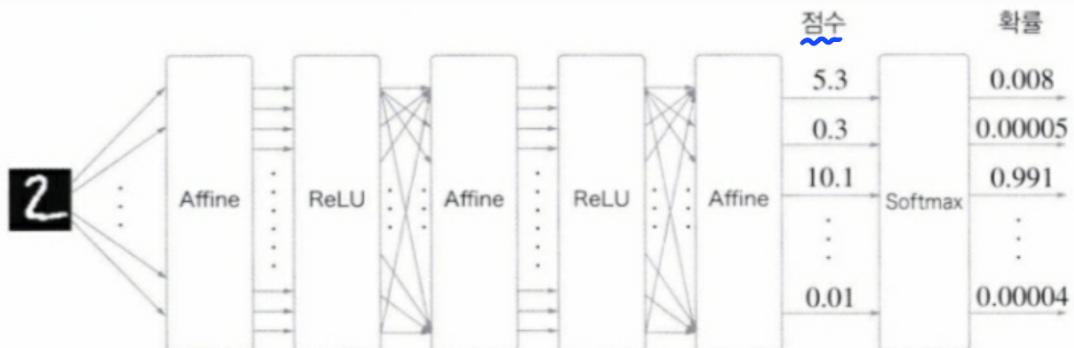
③ $\frac{\partial L}{\partial B} = \frac{\partial L}{\partial Y}$ 의 첫 번째 축(0축, 열방향)의 합
 $(3) \quad (N, 3)$



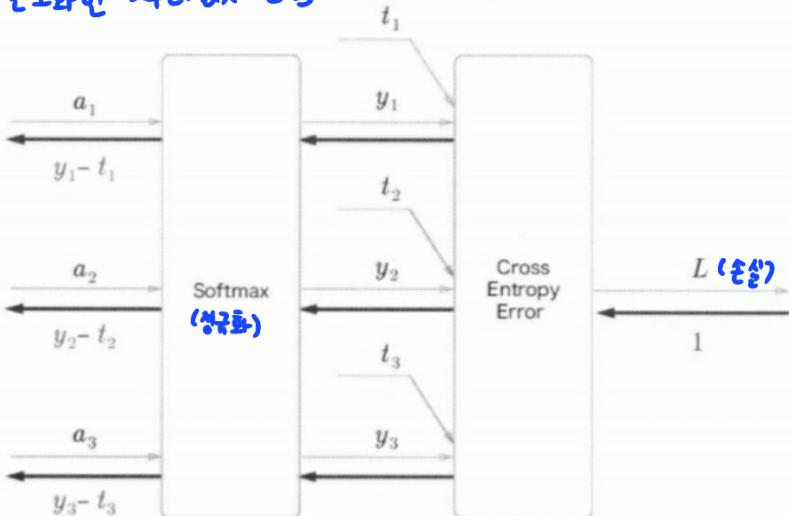
⇒ 배치용 Affine 계층

- Softmax-with-Loss

: softmax function은 입력값을 정규화하여 출력한다.



간소화한 Softmax - Loss



Softmax 결과와
정답 레이블의 차분

오차 역전파법의 구현

전제

신경망에는 적응 가능한 가중치와 편향이 있고, 이 가중치와 편향을 훈련 데이터에 적응하도록 조정하는 과정을 '학습'이라 합니다. 신경망 학습은 다음과 같이 4단계로 수행합니다.

1단계 – 미니배치

훈련 데이터 중 일부를 무작위로 가져옵니다. 이렇게 선별한 데이터를 미니배치라 하며, 그 미니배치의 손실 함수 값을 줄이는 것이 목표입니다.

2단계 – 기울기 산출

미니배치의 손실 함수 값을 줄이기 위해 각 가중치 매개변수의 기울기를 구합니다. 기울기는 손실 함수의 값 을 가장 작게 하는 방향을 제시합니다.

3단계 – 매개변수 갱신

가중치 매개변수를 기울기 방향으로 아주 조금 갱신합니다.

4단계 – 반복

1~3단계를 반복합니다.